**GFPI-F-135 REALIZA EL PROCESO DE LIMPIEZA DE DATOS**
**LIMPIEZA DE DATOS CON PYTHON**

**ACTIVIDADES POR DESARROLLAR:**

1. Datos faltantes
2. Columnas irrelevantes (que no responden al problema a solucionar
3. Filas repetidas
4. Valores extremos o atípicos (outliers)
5. Errores tipográficos.
6. Formatos de fechas


Para realizar el taller se debe descargar el DATASET "COVID19-JULIO2020", que corresponde a los datos del ICFES SABERPRO de 2012 calendario A.

Situaciones para realizar limpieza en los datos:

- Datos faltantes
- Columnas irrelevantes (que no responden al problema a solucionar
- Filas repetidas
- Valores extremos o atípicos (OUTLIERS)
- Errores tipográficos.
- Formatos de fechas

- **Remover duplicados o datos irrelevantes:** Tener datos duplicados sucede en la etapa de recolección de datos. Al tener diversas fuentes, se busca juntar los datos, lo que puede resultar en tener duplicados y se deben descartar filas repetidas. Los

datos irrelevantes no influyen o no impactan al problema que se está intentando solucionar.

- **Corregir errores estructurales:** Cuando observan nomenclaturas extrañas, errores tipográficos o gramaticales.
- **Corregir *outliers*:** o valor atípico es aquel que se esta por encima o por debajo del rango normal de valores de la variable que se está estudiando.
- **Manejo de datos faltantes:** Son aquellos vacíos de datos en la información recolectada. Existen opciones para tratar los datos faltantes:
  - **Eliminar todos los registros que contengan datos faltantes en algún campo:** Siempre y cuando los registros a eliminar sean mínimos. Si son un porcentaje importante de los datos, más del 10%, es mejor considerar otra alternativa.
  - **Reemplazar los datos faltantes por valores basados en otras observaciones:** Existen varias técnicas para esto (utilizar knn o algoritmo de vecinos cercanos, predecir los datos faltantes, etc.), lo más común es reemplazar por el promedio, o por la mediana (en el caso que el promedio esté sesgado por algunos valores dentro de los datos).

## Comandos utilizados en Python

## Detección de datos nulos

**Isnull:** Nos permite detectar datos nulos, simplificando este proceso independientemente de la dimensión de nuestra base de datos.

**Notnull:** Es la indicación lógica contraria, y la forma de llamar a la función es similar.

## Limpieza de Datos

**Dropna:** Elimina las filas que contienen datos nulos.

**Fillna:** Rellena los valores nulos con un valor predeterminado.

**Bfill:** Este método de fillna rellena los datos nulos, con base al valor de la siguiente fila.

- *Ventajas*: Este método es mejor que asignar un valor arbitrario a los datos, además garantiza que los datos se mantengan dentro de un rango específico. Es útil en bases de datos de gran extensión y con poca proporción de datos nulos.
- *Desventajas*: Se debe asegurar que el número de datos nulos NO sea significativo, para que el coeficiente de variación y otras medidas de dispersión no sufran de un sesgo muy grande.

## Datos erróneos e irrelevantes.

La reducción de la dimensionalidad produce una representación más compacta y más fácilmente interpretable del concepto de objetivo, centrando la atención del usuario en las variables más relevantes.

Utilizar las siguientes librerías

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

Descargar el DATASET, descomprimir, colocar en la variable ruta el lugar donde se descargó el archivo, no olvide de no utilizar "\" sino "/" para construir la ruta.

Cargar el archivo CSV

```
data=pd.read_csv(ruta)
print(data.shape)
```

Realizar el inventario de filas y tipos

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 400489 entries, 0 to 400488
Data columns (total 11 columns):
ID              400489 non-null int64
FECHA           400489 non-null object
DIVIPOLA        400489 non-null int64
CIUDAD          400489 non-null object
DEPARTAMENTO    400489 non-null object
ATENCION        399277 non-null object
EDAD            400489 non-null int64
SEXO            400489 non-null object
TIPO            400489 non-null object
ESTADO          398910 non-null object
PAIS            920 non-null object
dtypes: int64(3), object(8)
memory usage: 33.6+ MB
```

Subniveles de las categorías

```
cols_cat=['PAIS','CIUDAD','SEXO','TIPO','ESTADO','ATENCION' ,'DEPARTAMENTO']
for col in cols_cat:
    print(f'Columna {col}: {data[col].nunique()} subniveles')
```

Descubra y arregle el por qué sale un error al ejecutar la sentencia

```
Columna PAIS: 49 subniveles
Columna CIUDAD: 871 subniveles
Columna SEXO: 4 subniveles
Columna TIPO: 6 subniveles
Columna ESTADO: 6 subniveles
Columna ATENCION: 5 subniveles
Columna DEPARTAMENTO: 37 subniveles
```

Medidas de tendencias central

**data.describe()**

| | ID | DIVIPOLA | EDAD |
|---|---|---|---|
| count | 400489.000000 | 400489.000000 | 400489.000000 |
| mean | 207136.763996 | 24228.489584 | 39.378647 |
| std | 130326.805430 | 24497.916534 | 18.054488 |
| min | 1.000000 | 5001.000000 | 0.000000 |
| 25% | 100173.000000 | 8758.000000 | 27.000000 |
| 50% | 200302.000000 | 11001.000000 | 37.000000 |
| 75% | 300464.000000 | 25754.000000 | 51.000000 |
| max | 997851.000000 | 99524.000000 | 107.000000 |

**data.hist('EDAD')**

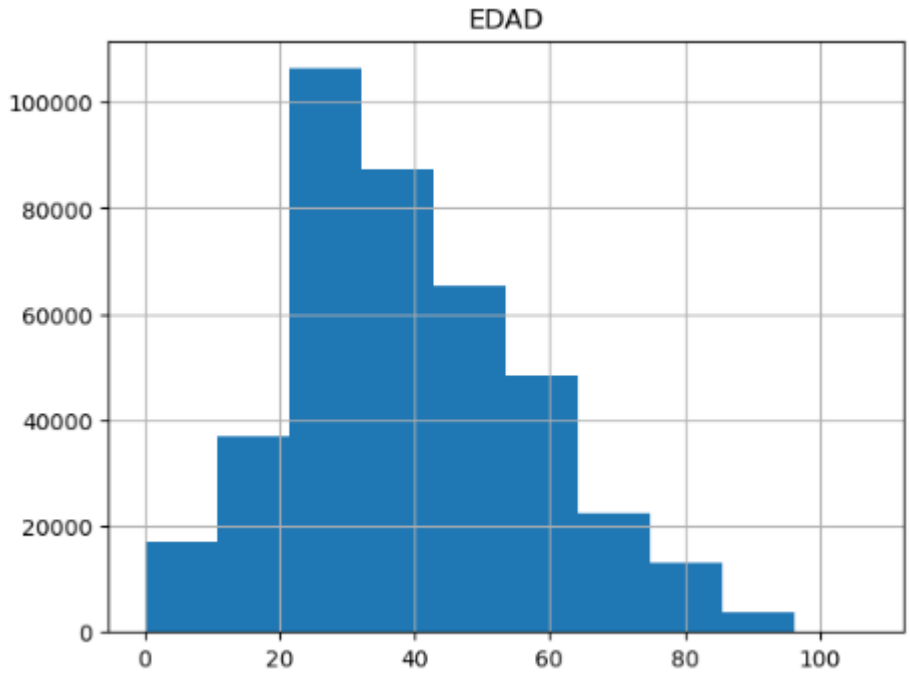


Quitar filas duplicadas

**print(data.shape)**

```
data.drop_duplicates(inplace=True)
print(data.shape)
```

```
(400489, 11)
(400489, 11)
```

Graficar las cantidades de filas en columnas numéricas, identificar outliers

```
boxplot = data.boxplot(column=['EDAD'])
```

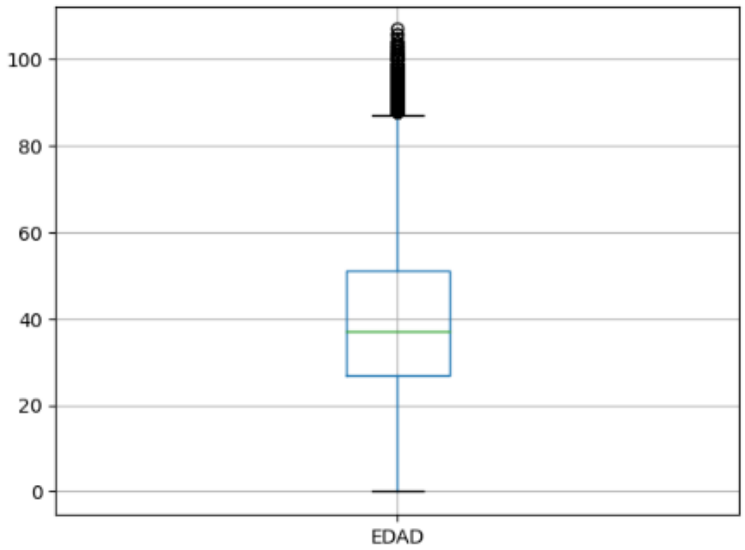


Identificar errores tipográficos:

```
colsnum=['SEXO','ATENCION','TIPO','ESTADO']
fig,aix=plt.subplots(nrows=4,ncols=1,figsize=(8,30))
fig.subplots_adjust(hspace=1)

for i,col in enumerate(colsnum):
   aix[i].set_title(col)
   sns.countplot(x=col,data=data,ax=aix[i])
```

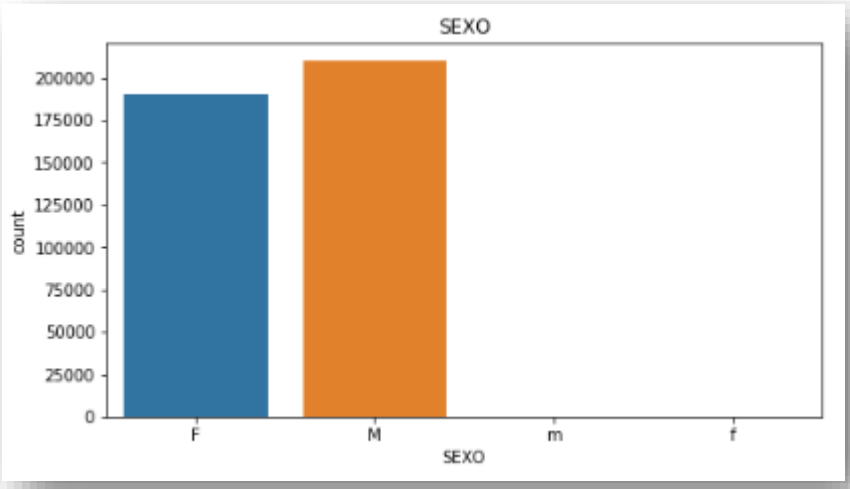

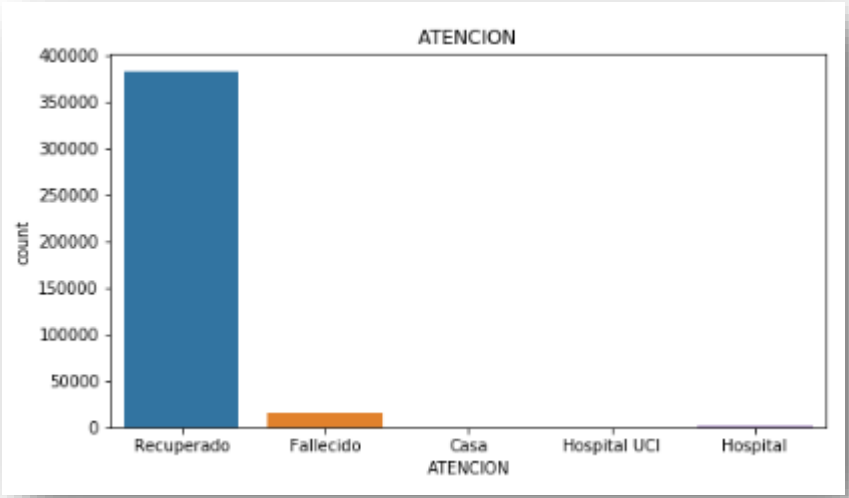

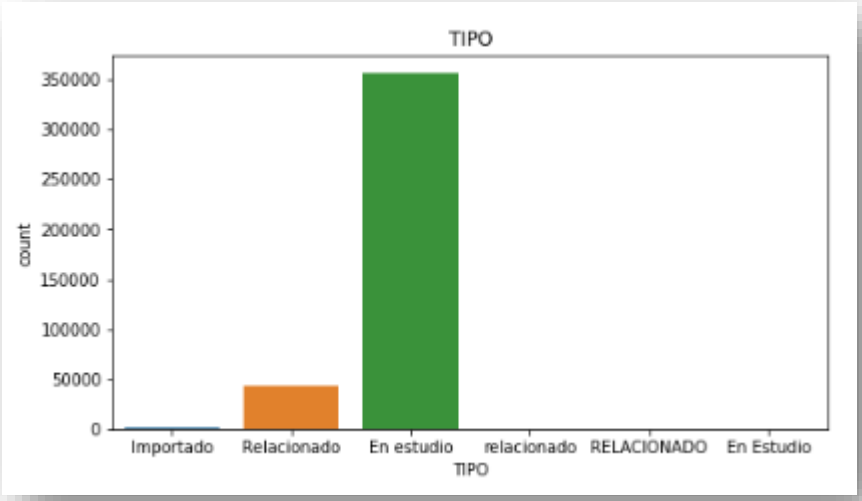


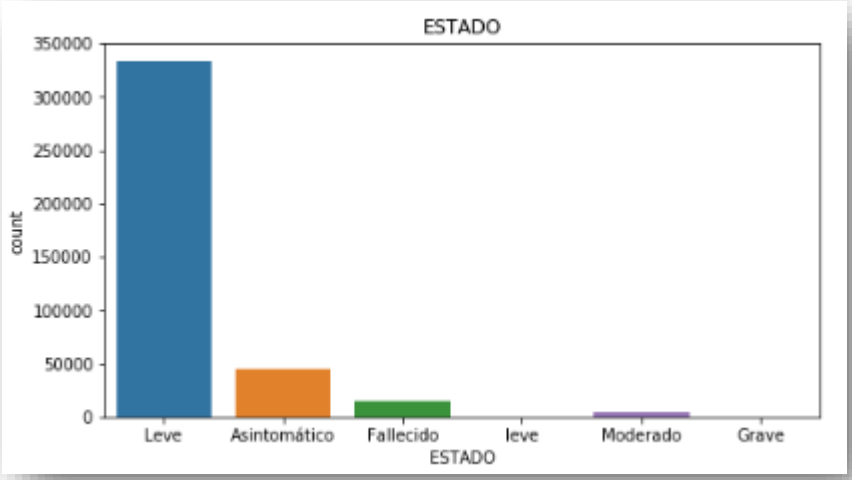

## Cambios de errores tipográficos.

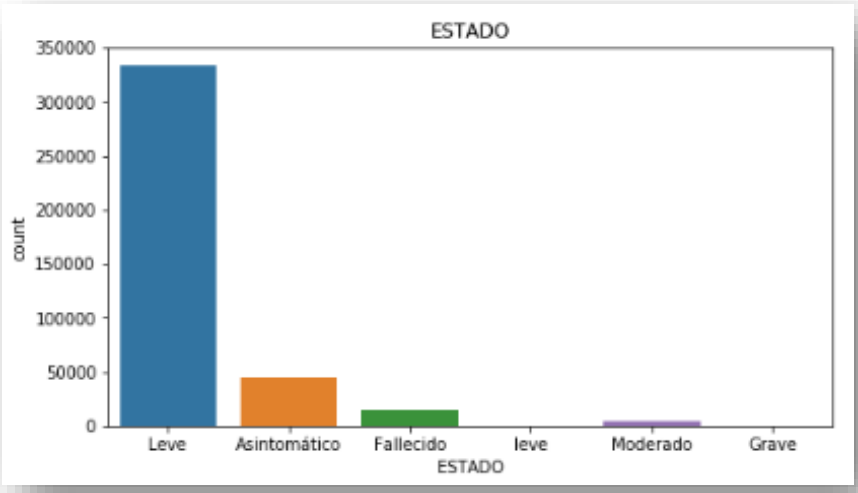


En el caso de la variable “Estado”, encontramos valores diferente que fueron escritos mal, por ejemplo “Leve y leve”.

Para realizar el cambio:

```
print(data['ESTADO'].unique())
data['ESTADO']=data['ESTADO'].str.replace('leve','Leve',regex=False)
print(data['ESTADO'].unique())
```

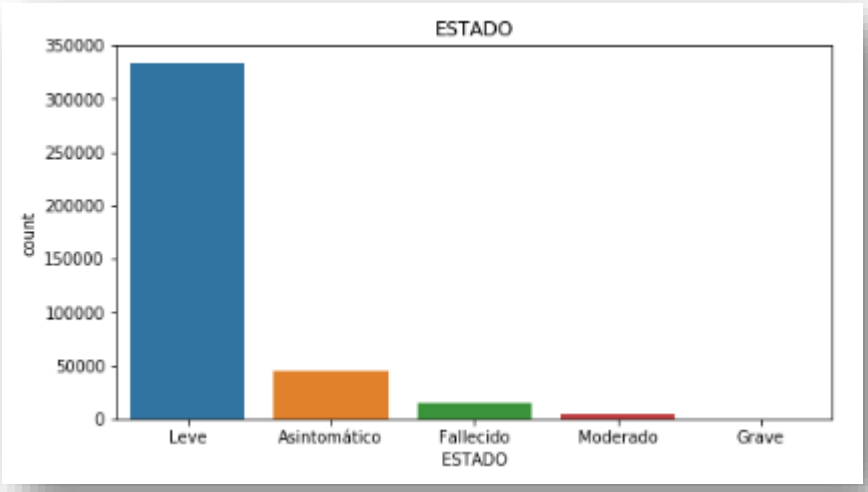

# MODELO ESTRELLA DEL COVID19

Convertir a CSV la dimensión “DM_ESTADO”

```
DA={
   'NOMBRE':data['ESTADO']
}
DM_ESTADO=pd.DataFrame(DA)
DM_ESTADO.drop_duplicates(inplace=True)

# agregar columna de consecutivo
DM_ESTADO['IDESTADO'] = range(1, len(DM_ESTADO) + 1)

# establecer columna "IDESTADO" como índice
DM_ESTADO.set_index('IDESTADO', inplace=True)

DM_ESTADO=DM_ESTADO.fillna('NA')
# mostrar DataFrame resultante
print(DM_ESTADO)
DM_ESTADO.to_csv('C:/borrar/DM_ESTADO.csv')
print('Guardado')
```

Convertir a CSV la dimensión “DM_TIPO”

```
DA={
   'NOMBRE':data['TIPO']
}
data['TIPO']=data['TIPO'].str.replace('relacionado','Relacionado',regex=False)
data['TIPO']=data['TIPO'].str.replace('RELACIONADO','Relacionado',regex=False)
data['TIPO']=data['TIPO'].str.replace('En Estudio','En estudio',regex=False)

DM_TIPO=pd.DataFrame(DA)
DM_TIPO.drop_duplicates(inplace=True)

# agregar columna de consecutivo
DM_TIPO['IDTIPO'] = range(1, len(DM_TIPO) + 1)

# establecer columna "IDTIPO" como índice
DM_TIPO.set_index('IDTIPO', inplace=True)

DM_TIPO=DM_TIPO.fillna('NA')
# mostrar DataFrame resultante
print(DM_TIPO)
DM_TIPO.to_csv('C:/borrar/DM_TIPO.csv')
print('Guardado')
```

```
            NOMBRE
IDTIPO
1         Importado
2       Relacionado
3        En estudio
4       relacionado
5       RELACIONADO
6        En Estudio
Guardado
```

Convertir a CSV la dimensión “DM_SEXO”

```
data['SEXO']=data['SEXO'].str.replace('m','M',regex=False)
data['SEXO']=data['SEXO'].str.replace('f','F',regex=False)

DM_SEXO=pd.DataFrame(data['SEXO'])
DM_SEXO.drop_duplicates(inplace=True)

# agregar columna de consecutivo
DM_SEXO['IDSEXO'] = range(1, len(DM_SEXO) + 1)

# establecer columna "IDSEXO" como índice
DM_SEXO.set_index('IDSEXO', inplace=True)

DM_SEXO=DM_SEXO.fillna('NA')
# mostrar DataFrame resultante
print(DM_SEXO)
DM_SEXO.to_csv('C:/borrar/DM_SEXO.csv')
print('Guardado')
```

```
        NOMBRE
IDSEXO
1            F
2            M
3            m
4            f
Guardado
```

Convertir a CSV la dimensión “DM_ATENCION”

```
data['ATENCION']=data['ATENCION'].str.replace('Hospital UCI','UCI',regex=False)

DM_ATENCION=pd.DataFrame(data['ATENCION'])
DM_ATENCION.drop_duplicates(inplace=True)

# agregar columna de consecutivo
DM_ATENCION['IDATENCION'] = range(1, len(DM_ATENCION) + 1)

# establecer columna "IDATENCION" como índice
DM_ATENCION.set_index('IDATENCION', inplace=True)

DM_ATENCION=DM_ATENCION.fillna('NA')
# mostrar DataFrame resultante
print(DM_ATENCION)
DM_ATENCION.to_csv('C:/borrar/DM_ATENCION.csv')
print('Guardado')
```

```
                NOMBRE
IDATENCION
1            Recuperado
2             Fallecido
3                    NA
4                  Casa
5           Hospital UCI
6              Hospital
Guardado
```

Convertir a CSV la dimensión “DM_DEPARTAMENTO”

```
DA={
   'IDDPTO':data['DIVIPOLA']//1000,
   'NOMBRE':data['DEPARTAMENTO']
}

DM_DEPARTAMENTO=pd.DataFrame(DA)
DM_DEPARTAMENTO.drop_duplicates(inplace=True)
DM_DEPARTAMENTO.set_index('IDDPTO', inplace=True)

# mostrar DataFrame resultante
print(DM_DEPARTAMENTO)
DM_DEPARTAMENTO.to_csv('C:/borrar/DM_DEPARTAMENTO.csv')
print('Guardado')
```

| IDDPTO | NOMBRE |
|---|---|
| 11 | Bogotá D.C. |
| 76 | Valle del Cauca |
| 5 | Antioquia |
| 13 | Cartagena D.T. y C. |
| 41 | Huila |
| 50 | Meta |
| 66 | Risaralda |
| 54 | Norte de Santander |
| 17 | Caldas |
| 25 | Cundinamarca |
| 8 | Barranquilla D.E. |
| 68 | Santander |
| 63 | Quindío |
| 73 | Tolima |
| 19 | Cauca |
| 47 | Santa Marta D.T. y C. |
| 20 | Cesar |
| 88 | Archipiélago de San Andrés Providencia y Santa... |
| 85 | Casanare |
| 52 | Nariño |
| 8 | Atlántico |
| 15 | Boyacá |
| 23 | Córdoba |
| 13 | Bolívar |
| 70 | Sucre |
| 47 | Magdalena |
| 44 | La Guajira |
| 76 | Buenaventura D.E. |
| 27 | Chocó |
| 91 | Amazonas |
| 18 | Caquetá |
| 86 | Putumayo |
| 81 | Arauca |
| 97 | Vaupés |
| 94 | Guainía |
| 99 | Vichada |
| 95 | Guaviare |

Guardado

Convertir a CSV la dimensión " DM_CIUDAD"

```
DA={
   'IDCIUDAD':data['DIVIPOLA'],
   'NOMBRE':data['CIUDAD']
}

DM_CIUDAD=pd.DataFrame(DA)
DM_CIUDAD.drop_duplicates(inplace=True)
DM_CIUDAD.set_index('IDCIUDAD', inplace=True)

# mostrar DataFrame resultante
print(DM_CIUDAD)
DM_CIUDAD.to_csv('C:/borrar/DM_CIUDAD.csv')


print('Guardado')
```

```
                    NOMBRE
IDCIUDAD
11001             Bogotá D.C.
76111     Guadalajara de Buga
5001                 Medellín
5360                   Itagüí
13001     Cartagena de Indias
...                        ...
68176                  Chima
76616                Riofrío
5036              Angelópolis
50318                 Guamal
19785                  Sucre

[937 rows x 1 columns]
Guardado
```

Convertir a CSV la dimensión " DM_FECHA"

```
DM_FECHA=pd.DataFrame(data['FECHA'])
DM_FECHA.drop_duplicates(inplace=True)

DM_FECHA['IDFECHA'] = range(1, len(DM_FECHA) + 1)
DM_FECHA.set_index('IDFECHA', inplace=True)

# mostrar DataFrame resultante
print(DM_FECHA)
DM_FECHA.to_csv('C:/borrar/DM_FECHA.csv')
```

```
                          FECHA
IDFECHA
1         2020-03-02T00:00:00.000
2         2020-03-06T00:00:00.000
3         2020-03-07T00:00:00.000
4         2020-03-09T00:00:00.000
5         2020-03-10T00:00:00.000
...                           ...
145       2020-07-18T00:00:00.000
146       2020-07-21T00:00:00.000
147       2020-07-22T00:00:00.000
148       2020-07-31T00:00:00.000
149       2020-07-25T00:00:00.000

[149 rows x 1 columns]
```

Crea la función fn_dimension para encontrar el ID de una dimensión dada

```
def fn_dimension(modelo,clave,valor):
    x=modelo[modelo[clave]==valor]
    if len(x)>0:
        return x.index[0]
    else:
        return -1
print(fn_dimension(DM_ATENCION,'NOMBRE','Casa'))
```

Remplazar datos de las tablas dimensiones en la tabla de hecho

```
data.columns = data.columns.str.replace('TIPO', 'IDTIPO') # renombrar la columna TIPO por IDTIPO
data['IDTIPO']=data.IDTIPO.str.replace('Importado','1',regex=False) #cambio en valor Importado por 1
data['IDTIPO']=data.IDTIPO.str.replace('Relacionado','2',regex=False) #cambio en Relacionado por 2


data.columns = data.columns.str.replace('ESTADO', 'IDESTADO') #Cambio el nombre de la columna
data.columns = data.columns.str.replace('DIVIPOLA', 'IDCIUDAD') #Cambio el nombre de la columna
data['IDESTADO']=data.IDESTADO.str.replace('Leve','1',regex=False) ) #cambio en Leve por 1
data['IDESTADO']=data.IDESTADO.str.replace('Asintomático','2',regex=False) ) #cambio en 'Asintomático'por 2
data.columns = data.columns.str.replace('ATENCION', 'IDATENCION') #Cambio el nombre de la columna
data['IDATENCION']=data.IDATENCION.str.replace('Recuperado','1',regex=False) ) #cambio Recuperado por 1
data['IDATENCION']=data.IDATENCION.str.replace('Fallecido','2',regex=False) ) #cambio Fallecido por 2
data['IDATENCION']=data.IDATENCION.str.replace('NA','3',regex=False) ) #cambio NA por 3
data['IDATENCION']=data.IDATENCION.str.replace('Casa','4',regex=False) ) #cambio Casa por 4
data['IDATENCION']=data.IDATENCION.str.replace('UCI','5',regex=False) ) #cambio UCI por 5
data['IDATENCION']=data.IDATENCION.str.replace('Hospital','6',regex=False) ) #cambio Hospital  por 6

data.set_index('ID', inplace=True) # coloco ID como columna index
data['DEPARTAMENTO']=data['IDCIUDAD']//1000 # tomo los dos dígitos de IDCIUDAD
data.columns = data.columns.str.replace('DEPARTAMENTO', 'IDDPTO') # renombro la columna

del(data['CIUDAD']) #Borro la columna CIUDAD
data.to_csv('C:/borrar/TH_COVID19.csv') #Creo el archivo CSV
```

Revisamos los subniveles

```
cols_cat=['PAIS','CIUDAD','SEXO','IDTIPO','IDESTADO','IDATENCION','DEPARTAMENTO']
for col in cols_cat:
   print(f'Columna {col}: {data[col].nunique()} subniveles')
```

```
Columna PAIS: 49 subniveles
Columna CIUDAD: 871 subniveles
Columna SEXO: 2 subniveles
Columna IDTIPO: 3 subniveles
Columna IDESTADO: 5 subniveles
Columna IDATENCION: 5 subniveles
Columna DEPARTAMENTO: 37 subniveles
```

Cargo los dataframe

```
data=pd.read_csv('c:/borrar/TH_COVID19.csv')
pais=pd.read_csv('c:/borrar/DM_PAIS.csv')
```

Busco el id del país

```
z1=pais['IDPAIS'] #cargo la columna idpais
z2=pais['NOMBRE'] #cargo la columna del nombre del pais

for idpais,nombre in zip(z1,z2): # recorro y empaqueto los dos vectores
    data['PAIS']=data.PAIS.str.replace(nombre,str(idpais),regex=False) #remplazo el nombre del pais con el idpais

data
```

Creamos la tabla de hechos

```
data.columns = data.columns.str.replace('PAIS', 'IDPAIS') # se renombra el pais
data.set_index('ID', inplace=True)
data.to_csv('C:/borrar/TH_COVID19.csv') # escribir el CSV de la tabla de hecho
```

# MODELO ESTRELLA COVID19

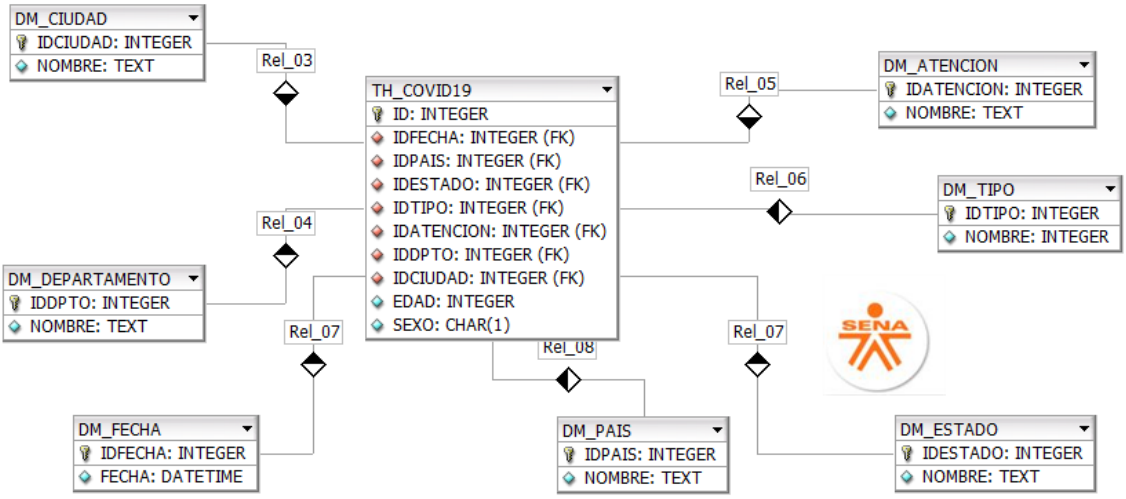


Cargar los datos generados en una base de datos MySQL llamada “COVID19”, mediante un programa Python, de acuerdo al modelo relacional presentado

**EVIDENCIA(S) A ENTREGAR:**
Aplicar las técnicas y métodos de limpieza de datos utilizando un DATASET propuesto por el instructor (SB11-20121-RGSTRO-CLFCCN-V1-0-txt).

**CONTROL DEL DOCUMENTO**

| | Nombre | Cargo | Dependencia | Fecha |
|---|---|---|---|---|
| **Autor (es)** | José Fernando Galindo Suarez | Instructor | CGMLTI-Teleinformática | 13/05/2023 |

**CONTROL DE CAMBIOS** (diligenciar únicamente si realizan ajustes al taller)

| | Nombre | Cargo | Dependencia | Fecha | Razón del Cambio |
|---|---|---|---|---|---|
| **Autor (es)** | | | | | |